

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»**

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

Отчет о программном проекте

на тему: _____ Чат-бот для абитуриентов _____

(промежуточный, этап 1)

Выполнил:

Студент группы БПМИ2412 _____

Веляев

Подпись

А.В.Веляев

И.О.Фамилия

02.02.2026

Дата

Принял:

Руководитель проекта _____

Андреева Дарья Александровна

Имя, Отчество, Фамилия

Старший инженер нейронных сетей

Должность, ученое звание

ООО "ИТ ИКС 5 ТЕХНОЛОГИИ"

Место работы (Компания или подразделение НИУ ВШЭ)

Москва 2026

Содержание

1	Введение	4
1.1	Актуальность	4
1.2	Цели	4
1.3	Задачи	4
1.4	Обзор литературы	4
2	Ход работы	5
2.1	Подготовка данных	5
2.2	Подготовка тестовой выборки	5
2.3	Выбор модели и Embedding	5
2.4	Первые результаты	6
2.4.1	Пример работы системы	6
2.4.2	Анализ выявленных проблем	6
	Список литературы	7

Аннотация

В данной работе разработан чат-бот в Telegram для автоматизации ответов на вопросы абитуриентов. Цель проекта - разгрузка учебного офиса в пиковые периоды приемной кампании. Бот предоставляет мгновенную информацию из официальных источников и фильтрует нецелевые запросы, обеспечивая поддержку до 5000 пользователей.

Ключевые слова: Python, RAG-архитектура, векторная база данных ChromaDB, эмбединги BGE-M3, автоматизация приемной комиссии, НИУ ВШЭ.

1 Введение

В последнее десятилетие технологии искусственного интеллекта и большие языковые модели (LLM) активно используются для автоматизации взаимодействия с пользователями в цифровой среде. В образовательном секторе, в частности в НИУ ВШЭ, внедрение таких технологий имеет особое значение для обработки обращений пользователей. В периоды пиковых нагрузок, во время приёмных кампаний, учебный офис сталкивается с резким ростом числа обращений. Традиционные методы информирования предполагают самостоятельное изучение пользователями объёмных нормативных документов, что существенно снижает оперативность получения ответов и приводит к перегрузке учебных офисов. В связи с этим разработка интеллектуальных систем, способных автоматизировать процесс консультаций, становится приоритетной задачей. Целью данного проекта является анализ и практическая реализация архитектуры Retrieval-Augmented Generation (RAG) для создания отказоустойчивого чат-бота, ориентированного на абитуриентов. Разрабатываемая система предназначена для предоставления оперативных ответов, основанных исключительно на официальных документах, регламентирующих процесс поступления. Такой подход позволяет минимизировать риск генерации недостоверной информации. В отчёте подробно описываются принципы работы с векторными эмбедами (BGE-M3), приводится характеристика реализованного функционала системы, а также представлены результаты тестирования на реальных наборах данных.

1.1 Актуальность

Рост числа обращений абитуриентов в периоды приёмных кампаний создаёт значительную нагрузку на учебные офисы и снижает оперативность предоставления ответов. Традиционные способы информирования, а именно изучении нормативных документов, оказываются недостаточно эффективными, поэтому целесообразно использовать чат-бота, который обеспечивает мгновенную обратную связь и удобен для пользователей.

1.2 Цели

1. Обеспечить абитуриентов и их родителей инструментом для получения мгновенных ответов на вопросы о поступлении в режиме 24/7 без участия человека.
2. Автоматизировать обработку простых вопросов для разгрузки сотрудников приемной комиссии.

1.3 Задачи

1. Сбор и структурирование датасета на основе официальных источников НИУ ВШЭ.
2. Предобработка текстовых данных и выбор модели.
3. Создание векторного хранилища данных для быстрого поиска по документам.
4. Разработка программной логики чат-бота в Telegram.
5. Проектирование пользовательского интерфейса и команд бота.
6. Тестирование системы на точность ответов и устойчивость к нагрузкам.
7. Проверка корректности ответов на наборе контрольных вопросов.

1.4 Обзор литературы

Теоретический анализ методов векторного представления текста (эмбедингов) базируется на материалах учебника Школы анализа данных (ШАД) Яндекса [4]. Изучение данных принципов позволило обосновать выбор современной модели BGE-M3 [5]. В работе П. Льюиса [6] была предложена архитектура RAG (Retrieval-Augmented Generation), сочетающая параметрическую память языковой модели и непараметрическую память внешнего корпуса документов, что стало важным этапом в развитии вопросно-ответных систем. В отличие от стандартных кнопочных ботов, архитектура RAG позволяет обрабатывать свободные запросы и обеспечивать точность ответов за счёт прямого поиска по заданным документам. Применение данного подхода в текущем проекте является ключевым фактором, позволяющим минимизировать риск возникновения «галлюцинаций» и обеспечить высокую точность ответов на основе официальных документов НИУ ВШЭ.

2 Ход работы

В данном разделе описывается процесс практической реализации. Работа разделена на несколько ключевых этапов: подготовка данных, выбор модели и Embedding, первые результаты.

2.1 Подготовка данных

На данном этапе я выбрал 3 самых важных документа с сайта ВШЭ об правилах приёма в 2026 году. Согласно материалам учебника Школы анализа данных (ШАД) Яндекса [4], огромные документы нужно делить на куски, потому что большие тексты будут обрабатываться очень долго и требовать много памяти, поэтому я извлек из pdf чистый текст, убрав при этом лишние элементы, и разделил их на части по абзацам (это примерно 500-1000 знаков). Чтобы это сделать, я использовал Python библиотеку - pdfplumber [7].

2.2 Подготовка тестовой выборки

Тестовый датасет для оценки системы был сформирован на основе анализа типичных запросов абитуриентов в приемную комиссию НИУ ВШЭ. В выборку из 50 тестовых запросов вошли вопросы про правила приема, перечень необходимых документов, сроки подачи заявлений, минимальные баллы по предметам и учет индивидуальных достижений (например, дополнительные баллы за наличие золотого значка ГТО). Для каждого вопроса был подготовлен правильный ответ, найденный в официальных документах университета.

2.3 Выбор модели и Embedding

В рамках данной работы был выполнен выбор модели для получения векторных представлений текстовых данных. Для этого были протестированы две предобученные модели библиотеки SentenceTransformers [8]: *paraphrase-multilingual-MiniLM-L12-v2* [9] и *BAAI/bge-m3* [5]. Сравнение проводилось на наборе из 20 типичных вопросов абитуриентов, ответы на которые содержались в документах НИУ ВШЭ. Основным критерием оценки стала корректность понимания русскоязычных запросов и точность сопоставления их с официальными текстами. По результатам тестирования была выбрана модель *BAAI/bge-m3*. В отличие от первой модели, допускавшей некорректную выдачу контекста на китайском языке, *BGE-M3* продемонстрировала стабильную работу с русскоязычными запросами и точность сопоставления их с официальными документами.




Рис. 1: Сравнение языковой точности моделей MiniLM-L12 и BGE-M3

Для хранения полученных эмбедингов и быстрого поиска по ним была выбрана векторная база данных ChromaDB [2]. Данное решение было принято благодаря возможности локального хранения данных, высокой скорости семантического поиска и полной совместимости с используемой моделью эмбедингов BGE-M3.

2.4 Первые результаты

На этапе первичного тестирования был использован тестовый датасет, состоящий из пар «вопрос-ответ», составленных на основе используемых документов. Чтобы модель использовала только русский язык и отвечала только на те вопросы, данные о которых есть в источнике, был создан такой запрос:

«Ты - официальный ИИ-ассистент приемной комиссии ФКН НИУ ВШЭ. Используй предоставленный КОНТЕКСТ, чтобы ответить на ВОПРОС.

ПРАВИЛА:

- 1. Ответ должен быть только на русском языке.*
- 2. Будь точен в цифрах, баллах и датах.*
- 3. Если информации нет в контексте, так и скажи.*
- 4. В конце ответа обязательно укажи источник (ссылку и страницу).»*

2.4.1 Пример работы системы

Ниже представлен пример типичного запроса абитуриента и сформированного ответа системы на основе загруженных документов:

В: Минимальный балл по математике для программы Программная инженерия?

О: Минимальный балл по математике для программы Программная инженерия составляет 70 баллов.
Источник: (<https://ba.hse.ru/mirror/pubs/share/1120607478>)

2.4.2 Анализ выявленных проблем

Оценка качества ответов проводилась методом ручной разметки на основе тестовой выборки из 50 вопросов. В ходе анализа был выявлен ряд проблем, требующих доработки системы. В частности, наблюдались случаи генерации ответов на китайском языке, что указывает на необходимость модификации системного промпта для жесткой фиксации русского языка. Также были зафиксированы ошибки, когда модель предоставляла некорректную информацию, неверно считав её из документов. Кроме того, в некоторых сценариях система не выдавала ответ вообще, несмотря на наличие релевантной информации в базе знаний.




Рис. 2: Качество ответов на тестовых данных

Список литературы и источников

- [1] Руководство по созданию датасета для машинного обучения [Электронный ресурс] // Хабр. — 2025. — Режим доступа: https://habr.com/ru/companies/data_light/articles/896108/ (дата обращения: 05.01.2026).
- [2] Chroma Documentation: Getting Started [Электронный ресурс] // Chroma. — 2025. — Режим доступа: <https://docs.trychroma.com/docs/overview/getting-started> (дата обращения: 22.01.2025).
- [3] Рашка С. Python и машинное обучение [Текст] / С. Рашка, В. Мирджалили ; пер. с англ. А. В. Логунова. — Москва : ДМК Пресс, 2020. — 818 с.
- [4] Машинное обучение: учебник [Электронный ресурс] // Яндекс Образование : [сайт]. — 2025. — Режим доступа: <https://education.yandex.ru/handbook/ml> (дата обращения: 22.01.2025).
- [5] BGE-M3 Model Library [Электронный ресурс] // Ollama. — 2025. — Режим доступа: <https://ollama.com/library/bge-m3> (дата обращения: 02.02.2026).
- [6] Lewis P. et al. Retrieval-augmented generation for knowledge-intensive nlp tasks // Advances in Neural Information Processing Systems. — 2020. — Т. 33. — С. 9459-9474. URL: <https://arxiv.org/abs/2005.11401>
- [7] pdfplumber: Plumb a PDF for detailed information about each text character, rectangle, and line [Электронный ресурс] // PyPI. — URL: <https://pypi.org/project/pdfplumber/> (дата обращения: 03.02.2026).
- [8] Sentence Transformers: документация по обучению и использованию многоязычных моделей эмбедингов [Электронный ресурс] // SBERT.net. — URL: <https://sbert.net/> (дата обращения: 03.02.2026).
- [9] Paraphrase-multilingual-minilm:l12-v2 model — Ollama [Электронный ресурс] // Ollama Library. — URL: <https://ollama.com/nextfire/paraphrase-multilingual-minilm:l12-v2> (дата обращения: 03.02.2026).