

**ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»**

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

Отчет о программном проекте

на тему: _____ Чат-бот для абитуриентов _____

(промежуточный, этап 1)

Выполнил:

Студент группы БПМИ2412 _____



Подпись

А.В.Веляев

И.О.Фамилия

02.02.2026

Дата

Принял:

Руководитель проекта _____

Андреева Дарья Александровна

Имя, Отчество, Фамилия

Старший инженер нейронных сетей

Должность, ученое звание

ООО "ИТ ИКС 5 ТЕХНОЛОГИИ"

Место работы (Компания или подразделение НИУ ВШЭ)

Москва 2026

Содержание

1	Введение	4
1.1	Актуальность	4
1.2	Цели	4
1.3	Задачи	4
2	Обзор литературы	4
2.1	Подходы к построению вопросно-ответных систем	5
2.2	Обоснование выбора RAG	5
3	Архитектура системы	6
4	Ход работы	6
4.1	Подготовка данных	6
4.2	Подготовка тестовой выборки	6
4.3	Выбор модели векторного представления текста	7
4.4	Эксперимент 1	7
4.4.1	Анализ выявленных проблем	7
4.5	Эксперимент 2	8
4.5.1	Улучшения запроса пользователя	8
4.5.2	Оптимизация генерации ответа и контроль языковых аномалий	9
4.5.3	Метрики качества	9
	Список литературы	10

Аннотация

В данной работе разработан чат-бот в Telegram для автоматизации ответов на вопросы абитуриентов. Цель проекта - разгрузка учебного офиса в пиковые периоды приемной кампании. Бот предоставляет мгновенную информацию из официальных источников и фильтрует нецелевые запросы, обеспечивая поддержку до 5000 пользователей.

Ключевые слова: Python, RAG-архитектура, векторная база данных ChromaDB, эмбединги BGE-M3, автоматизация приемной комиссии, НИУ ВШЭ.

1 Введение

В последнее десятилетие технологии искусственного интеллекта и большие языковые модели (LLM) активно используются для автоматизации взаимодействия с пользователями в цифровой среде. В образовательном секторе, в частности в НИУ ВШЭ, внедрение таких технологий имеет особое значение для обработки обращений пользователей. В периоды пиковых нагрузок, во время приёмных кампаний, учебный офис сталкивается с резким ростом числа обращений. Традиционные методы информирования предполагают самостоятельное изучение пользователями объёмных нормативных документов, что существенно снижает оперативность получения ответов и приводит к перегрузке учебных офисов. В связи с этим разработка интеллектуальных систем, способных автоматизировать процесс консультаций, становится приоритетной задачей. Целью данного проекта является анализ и практическая реализация архитектуры Retrieval-Augmented Generation (RAG) для создания отказоустойчивого чат-бота, ориентированного на абитуриентов. Разрабатываемая система предназначена для предоставления оперативных ответов, основанных исключительно на официальных документах, регламентирующих процесс поступления. Такой подход позволяет минимизировать риск генерации недостоверной информации. В отчёте подробно описываются принципы работы с векторными эмбедами (BGE-M3), приводится характеристика реализованного функционала системы, а также представлены результаты тестирования на реальных наборах данных.

1.1 Актуальность

Рост числа обращений абитуриентов в периоды приёмных кампаний создаёт значительную нагрузку на учебные офисы и снижает оперативность предоставления ответов. Традиционные способы информирования, а именно изучении нормативных документов, оказываются недостаточно эффективными, поэтому целесообразно использовать чат-бота, который обеспечивает мгновенную обратную связь и удобен для пользователей.

1.2 Цели

1. Обеспечить абитуриентов и их родителей инструментом для получения мгновенных ответов на вопросы о поступлении в режиме 24/7 без участия человека.
2. Автоматизировать обработку простых вопросов для разгрузки сотрудников приемной комиссии.

1.3 Задачи

1. Сбор и структурирование датасета на основе официальных источников НИУ ВШЭ.
2. Предобработка текстовых данных и выбор модели.
3. Создание векторного хранилища данных для быстрого поиска по документам.
4. Разработка программной логики чат-бота в Telegram.
5. Проектирование пользовательского интерфейса и команд бота.
6. Тестирование системы на точность ответов и устойчивость к нагрузкам.
7. Проверка корректности ответов на наборе контрольных вопросов.

2 Обзор литературы

Разработка систем автоматического ответа на вопросы пользователей представляет собой активно развивающуюся область исследований, в которой сложились несколько принципиально различных подходов. В данном разделе рассматриваются основные из них применительно к задаче настоящего проекта — созданию чат-бота для ответов на вопросы абитуриентов НИУ ВШЭ на основе официальных документов.

2.1 Подходы к построению вопросно-ответных систем

Исторически первым решением стали кнопочные боты с фиксированными сценариями. Несмотря на детерминированность и легкость проверки, они принципиально ограничены невозможностью обработки произвольных запросов и необходимостью ручной переработки при любом изменении данных. Альтернативой выступает «закрытый» генеративный подход, где модель опирается только на знания, заложенные при обучении. Для задач, требующих точного следования регламентам университета, такой подход недостаточен, так как модель не имеет доступа к актуальным локальным актам и склонна генерировать правдоподобные, но неверные утверждения. Принципиальным решением стала архитектура *Retrieval-Augmented Generation* (RAG) [6]. Она сочетает генеративные способности LLM с внешним хранилищем документов. На каждый запрос система извлекает релевантные фрагменты текста и подает их модели в качестве контекста. Это обеспечивает строгую привязку ответа к источникам и позволяет обновлять базу знаний без переобучения нейросети.

2.2 Обоснование выбора RAG

С учётом ограничений и требований настоящего проекта архитектура RAG является наиболее подходящей по следующим соображениям. Во-первых, ответы должны основываться исключительно на официальных документах [НИУ ВШЭ](#), что делает генерацию «из параметров» недопустимой: риск галлюцинаций в высоких ставках юридически значимых сведений (сроки, условия поступления, требования к документам) критичен. Во-вторых, документы регулярно обновляются — RAG позволяет актуализировать базу без модификации модели.

3 Архитектура системы

Реализованная система представляет собой расширенный RAG-пайплайн с предварительным этапом переформулирования запроса (Query Rewriting). Необходимость данного этапа обусловлена семантическим разрывом между разговорным стилем пользовательских запросов и официально-деловым регистром нормативных документов: как показано в работе [10], прямой поиск по исходному запросу систематически уступает подходу «переформулировать — извлечь — ответить» (Rewrite-Retrieve-Read). На этапе Query Rewriting языковая модель трансформирует исходный запрос абитуриента в поисковый запрос, оптимизированный для семантического сопоставления с корпусом документов. Далее выполняется поиск в векторном хранилище ChromaDB с использованием эмбедингов BGE-M3, а отобранный релевантный контекст передаётся в генеративную модель для формирования финального ответа.




Рис. 1: Схема работы RAG-системы с Query Rewriting

4 Ход работы

В данном разделе описывается процесс практической реализации. Работа разделена на несколько ключевых этапов: подготовка данных, выбор модели и Embedding, первые результаты.

4.1 Подготовка данных

На данном этапе я выбрал 3 самых важных документа с сайта ВШЭ об правилах приёма в 2026 году. Согласно материалам учебника Школы анализа данных (ШАД) Яндекса [4], огромные документы нужно делить на куски, потому что большие тексты будут обрабатываться очень долго и требовать много памяти, поэтому я извлек из pdf чистый текст, убрав при этом лишние элементы, и разделил их на части по абзацам (это примерно 500-1000 знаков). Чтобы это сделать, я использовал Python библиотеку - pdfplumber [7].

4.2 Подготовка тестовой выборки

Тестовый датасет для оценки системы был сформирован на основе анализа типичных запросов абитуриентов в приемную комиссию НИУ ВШЭ. В выборку из 50 тестовых запросов вошли вопросы про правила приема, перечень необходимых документов, сроки подачи заявлений, минимальные баллы по предметам и учет индивидуальных достижений (например, дополнительные баллы за наличие золотого значка ГТО). Для каждого вопроса был подготовлен правильный ответ, найденный в официальных документах университета.

4.3 Выбор модели векторного представления текста

Для формирования эмбедингов текстовых данных были рассмотрены две предобученные модели из библиотеки SentenceTransformers [8]: *paraphrase-multilingual-MiniLM-L12-v2* [9] и *BAAI/bge-m3* [5]. Сравнительное тестирование проводилось на контрольной выборке из 20 верифицированных вопросов абитуриентов; в качестве метрик использовались стандартные показатели качества поиска информации (Information Retrieval): Hit Rate@3 и Mean Reciprocal Rank (MRR). Hit Rate@3 фиксирует долю запросов, для которых релевантный документ попадает в тройку лучших результатов; MRR отражает среднюю позицию правильного ответа в ранжированной выдаче и тем самым характеризует пригодность результатов для последующей генерации ответа языковой моделью. По итогам тестирования для реализации системы была выбрана модель *BAAI/bge-m3*. Она превзошла конкурента по обоим метрикам: в части Hit Rate@3 модель демонстрировала точное сопоставление семантики запроса с официальными документами, тогда как *paraphrase-multilingual-MiniLM-L12-v2* в ряде случаев возвращала нерелевантные контексты на иностранных языках. Показатель MRR также оказался выше, что свидетельствует о более качественном ранжировании: целевой фрагмент текста стабильно занимает верхние позиции выдачи, что существенно для корректной работы генеративного модуля.




Рис. 2: Сравнение языковой точности моделей MiniLM-L12 и BGE-M3

Для хранения полученных эмбедингов и быстрого поиска по ним была выбрана векторная база данных ChromaDB [2]. Данное решение было принято благодаря возможности локального хранения данных, высокой скорости семантического поиска и полной совместимости с используемой моделью эмбедингов BGE-M3.

4.4 Эксперимент 1

На этапе первичного тестирования был использован тестовый датасет, состоящий из пар «вопрос-ответ», составленных на основе используемых документов. Чтобы модель использовала только русский язык и отвечала только на те вопросы, данные о которых есть в источнике, был создан такой запрос:

«Ты - официальный ИИ-ассистент приемной комиссии ФКН НИУ ВШЭ. Используй предоставленный КОНТЕКСТ, чтобы ответить на ВОПРОС.

ПРАВИЛА:

- 1. Ответ должен быть только на русском языке.*
- 2. Будь точен в цифрах, баллах и датах.*
- 3. Если информации нет в контексте, так и скажи.*
- 4. В конце ответа обязательно укажи источник (ссылку и страницу).»*

4.4.1 Анализ выявленных проблем

Оценка качества ответов проводилась методом ручной разметки на основе тестовой выборки из 50 вопросов. В ходе анализа был выявлен ряд проблем, требующих доработки системы. В частности, наблюдались случаи

генерации ответов на китайском языке, что указывает на необходимость модификации системного промпта для жесткой фиксации русского языка. Также были зафиксированы ошибки, когда модель предоставляла некорректную информацию, неверно считав её из документов. Кроме того, в некоторых сценариях система не выдавала ответ вообще, несмотря на наличие релевантной информации в базе знаний.

4.5 Эксперимент 2

На втором этапе тестирования архитектура системы была модернизирована. Основным изменением стало внедрение модуля *Query Rewriting* на базе модели *Qwen 2.5*. Это позволило унифицировать запросы пользователей и повысить точность извлечения контекста из *ChromaDB*.

4.5.1 Улучшения запроса пользователя

Главная проблема при поиске по документам ВШЭ заключается в том, что абитуриенты используют сокращения и простые слова, а в официальных приказах используются сложные юридические термины. Чтобы поисковик (ChromaDB) мог найти правильный документ, нам нужно сначала «расшифровать» вопрос пользователя.

Для этого внедрил этап переписывания запроса (*Query Rewriting*). Система получает короткий вопрос от пользователя и, используя знания модели *Qwen 2.5*, превращает его в подробный запрос, который «понимает» база данных.

Ниже представлен системный промпт, который переписывает запрос пользователя.

Ты — поисковый эксперт НИУ ВШЭ. Твоя задача: перефразировать вопрос пользователя в точный поисковый запрос для базы данных.

ПРАВИЛА:

1. **ТЕРМИНОЛОГИЯ:** Обязательно расшифровывай сокращения. Пиши ПОЛНОЕ название, а в скобках само сокращение.

Список для расшифровки:

- ПМИ = Прикладная математика и информатика (ПМИ)
- ПИ = Программная инженерия (ПИ)
- ПАД = Прикладной анализ данных (ПАД)
- КБ = Компьютерная безопасность (КБ)
- ЭАД = Экономика и анализ данных (ЭАД)
- СПО = Среднее профессиональное образование (СПО)
- ЕГЭ = Единый государственный экзамен (ЕГЭ)
- БВИ = Без вступительных испытаний (БВИ)
- ЕПГУ = Единый портал государственных услуг (ЕПГУ)
- ГТО = Готов к труду и обороне (ГТО)

2. **ЗАМЕНЫ:** Если в вопросе есть слово "предметы" заменяй его на "вступительные испытания" или "учебные дисциплины".

3. **ФОКУС:** Не используй общие фразы про "компетенции если их нет в оригинале".

4. **ФОРМАТ:** Пиши ТОЛЬКО текст запроса на русском языке. Без кавычек и лишних фраз.

ПРИМЕРЫ:

-Вопрос: "Как поступить с БВИ на ЭАД?" Запрос: "Правила приема без вступительных испытаний (БВИ) на программу Экономика и анализ данных (ЭАД) НИУ ВШЭ"

-Вопрос: "Баллы ЕГЭ для СПО" Запрос: "Минимальные баллы Единого государственного экзамена (ЕГЭ) для абитуриентов со средним профессиональным образованием (СПО)"

-Вопрос: "Льготы за ГТО на ПМИ" Запрос: "Дополнительные баллы за золотой значок Готов к труду и обороне (ГТО) при поступлении на Прикладную математику и информатику (ПМИ)"

Благодаря этому этапу, система находит нужные документы даже тогда, когда абитуриент использует сленг или аббревиатуры.

4.5.2 Оптимизация генерации ответа и контроль языковых аномалий

На этапе Эксперимента 2 был существенно переработан системный промпт для генерации финального ответа. Основной целью модификации стало устранение выявленных ранее дефектов: самопроизвольного переключения модели на китайский или английский языки, а также предоставления избыточной информации, не относящейся к сути вопроса.

SYSTEM: *You are a professional assistant for HSE University (НИУ ВШЭ).*

Your tone must be official, formal, and strictly professional.

Language: Russian ONLY.

ИНСТРУКЦИЯ:

Ты — ведущий консультант приемной комиссии НИУ ВШЭ. Дай краткий и точный ответ на основе предоставленного КОНТЕКСТА.

ПРАВИЛА:

1. **ФОРМАТ:** Не используй технические заголовки типа "ПРЯМОЙ ОТВЕТ:" или "ШАБЛОН:". Просто пиши текст ответа.
2. **ЛОГИКА:** Если в контексте ЕСТЬ ответ на вопрос, пиши ТОЛЬКО его. Не добавляй фразы о том, что "информация не зафиксирована" для других программ.
3. **ТОЧНОСТЬ:** Пиши только про ту программу, о которой спросил пользователь. Не приводи данные по Информатике и выч. технике если вопрос про "ПМИ".
4. **ОТКАЗ:** Используй фразу "К сожалению, в предоставленных документах нет информации по данному вопросу" ТОЛЬКО если в контексте вообще нет данных по теме.
5. **ОФОРМЛЕНИЕ:** Ключевые цифры и названия программ выделяй ****жирным шрифтом****.

ПОРЯДОК ВЫВОДА:

- Сформулированный ответ на вопрос.
- Источник (название документа, ссылка и страница) в отдельной строке.

КОНТЕКСТ: {context}

ВОПРОС: {q}

ОТВЕТ:

4.5.3 Метрики качества

Для получения объективных показателей эффективности во втором эксперименте была использована методология *LLM-as-a-Judge*. В качестве экспертной модели выступала *Qwen 2.5*, которой в дополнение к паре «вопрос-ответ» передавался эталонный контекст для сопоставления.

Оценка проводилась по двум группам показателей: метрики Retrieval и Generation. Итоговые результаты представлены в таблице.

Метрика	Значение
Hit Rate@3	0,898
MRR@3	0,833
LLM Precision	2,53 / 5,00
LLM Recall	2,98 / 5,00

Таблица 1: Показатели эффективности системы в Эксперименте 2

Список литературы и источников

- [1] Руководство по созданию датасета для машинного обучения [Электронный ресурс] // Хабр. — 2025. — Режим доступа: https://habr.com/ru/companies/data_light/articles/896108/ (дата обращения: 05.01.2026).
- [2] Chroma Documentation: Getting Started [Электронный ресурс] // Chroma. — 2025. — Режим доступа: <https://docs.trychroma.com/docs/overview/getting-started> (дата обращения: 22.01.2025).
- [3] Рашка С. Python и машинное обучение [Текст] / С. Рашка, В. Мирджалили ; пер. с англ. А. В. Логунова. — Москва : ДМК Пресс, 2020. — 818 с.
- [4] Машинное обучение: учебник [Электронный ресурс] // Яндекс Образование : [сайт]. — 2025. — Режим доступа: <https://education.yandex.ru/handbook/ml> (дата обращения: 22.01.2025).
- [5] BGE-M3 Model Library [Электронный ресурс] // Ollama. — 2025. — Режим доступа: <https://ollama.com/library/bge-m3> (дата обращения: 02.02.2026).
- [6] Lewis P. et al. Retrieval-augmented generation for knowledge-intensive nlp tasks // Advances in Neural Information Processing Systems. — 2020. — Т. 33. — С. 9459-9474. URL: <https://arxiv.org/abs/2005.11401>
- [7] pdfplumber: Plumb a PDF for detailed information about each text character, rectangle, and line [Электронный ресурс] // PyPI. — URL: <https://pypi.org/project/pdfplumber/> (дата обращения: 03.02.2026).
- [8] Sentence Transformers: документация по обучению и использованию многоязычных моделей эмбедингов [Электронный ресурс] // SBERT.net. — URL: <https://sbert.net/> (дата обращения: 03.02.2026).
- [9] Paraphrase-multilingual-minilm:l12-v2 model — Ollama [Электронный ресурс] // Ollama Library. — URL: <https://ollama.com/nextfire/paraphrase-multilingual-minilm:l12-v2> (дата обращения: 03.02.2026).
- [10] Ma X. et al. Precise Zero-Shot Dense Retrieval without Relevance Labels [Электронный ресурс] // arXiv.org. — 2023. — URL: <https://arxiv.org/abs/2305.14283> (дата обращения: 17.03.2026).